Fully Convolutional Neural Network

Semantic Segementation 기초와 Fully Convolutional Neural Network for Semantic Segmentation 논문 이해하기

INDEX

Semantic Segmentation

Code Review

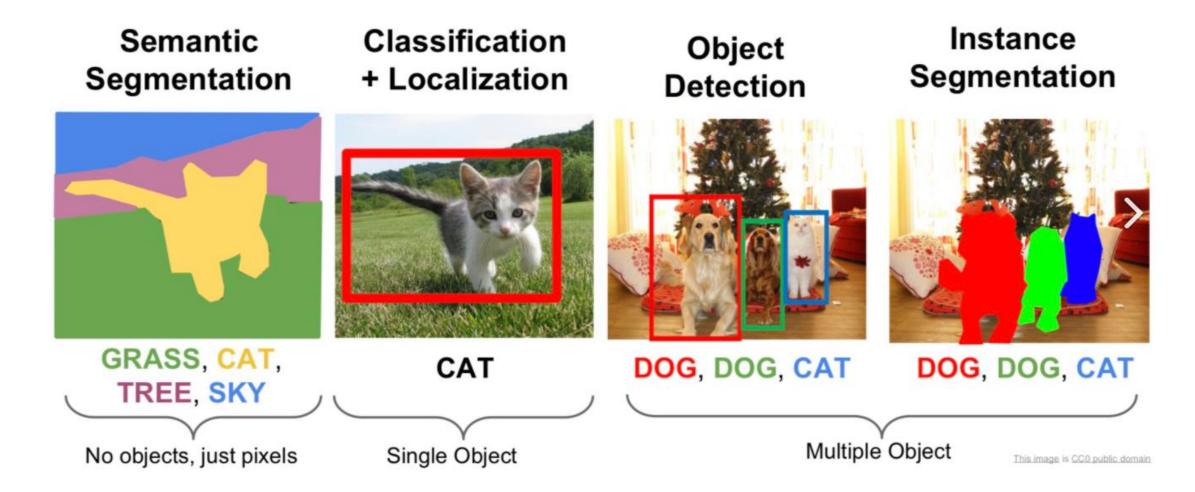




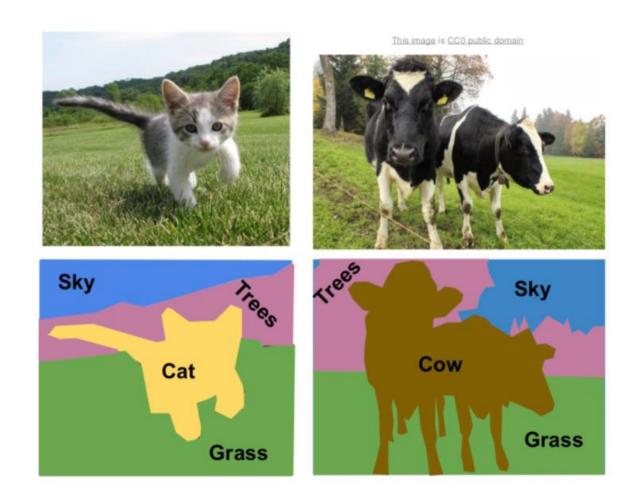
Fully Convolutional Networks

1 Semantic Segmentation이란?

• (1) Computer Vision Tasks



1 Semantic Segmentation이란? •(2) Semantic Segmentation

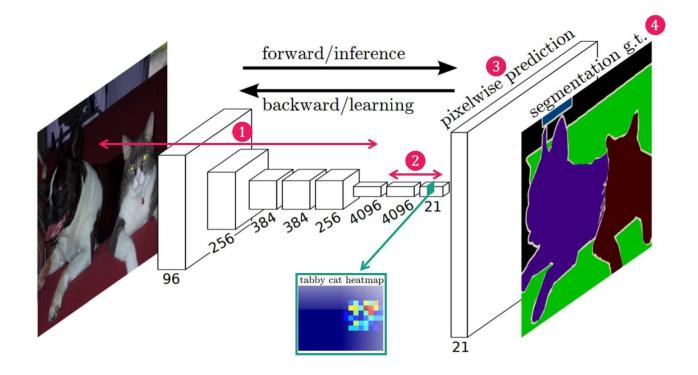


FCN



O. Abstract O. Abstract

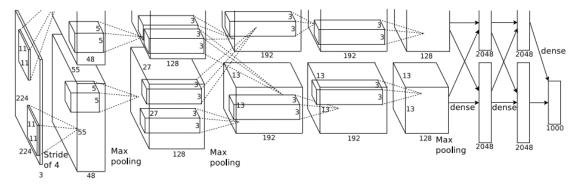
- ✓ Fully Convolutional Networks for semantic Segmentation[1]의 Contribution
 - 1. End-to-end 방식의 Semantic Segmentation 방법을 제안
 - 2. AlexNet을 시작으로 하는 CNN 계열 모델을 사용
 - 3. Fully Convolutional + Skip Architecture 두가지 방법을 도입
 - 4. 임의의 입력값에 대해서도 효율적인 Segmentation 결과를 생성 가능하고 SOTA 점수 달성



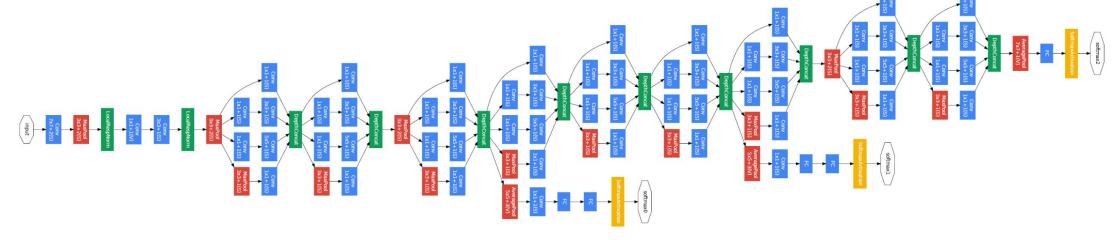
Introduction • (1) Convolutional networks

✓ Recognition에서 Deep Learning 네트워크의 개발에 따른 다른 분야로의 확장

AlexNet (2012) [2]



VGG[3], GoogleNet[4] (2014)

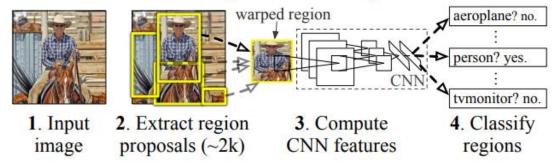


Introduction • (1) Convolutional networks

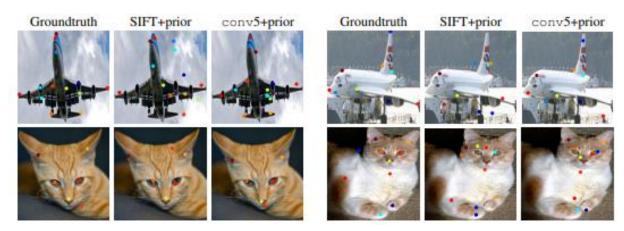
✓ Recognition에서 Deep Learning 네트워크의 개발에 따른 다른 분야로의 확장

Bounding Box object detection [5]

R-CNN: Regions with CNN features



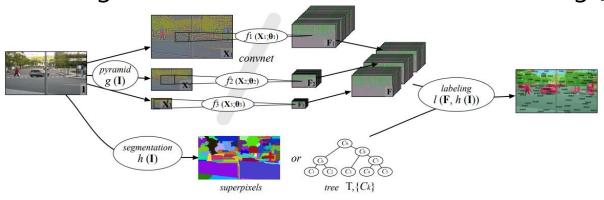
Key point prediction [6]



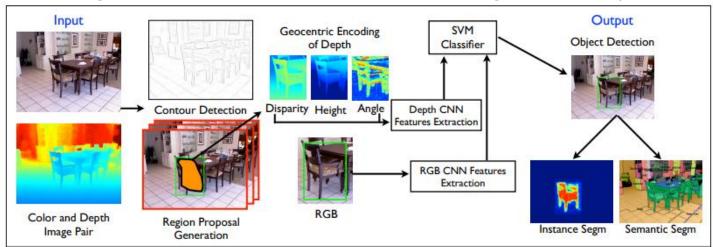
Introduction • (1) Convolutional networks

Prior Approaches convnets for semantic segmentation

Learning hierarchical features for scene labeling [7]

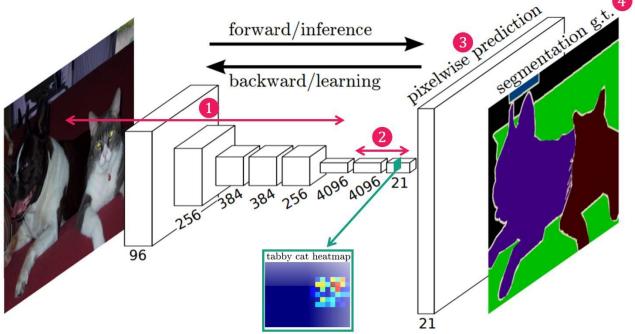


Learning Rich Features from RGB-D Images for Object Detection and Segmentation [8]



• (2) Fully Convolutional Network (FCN)

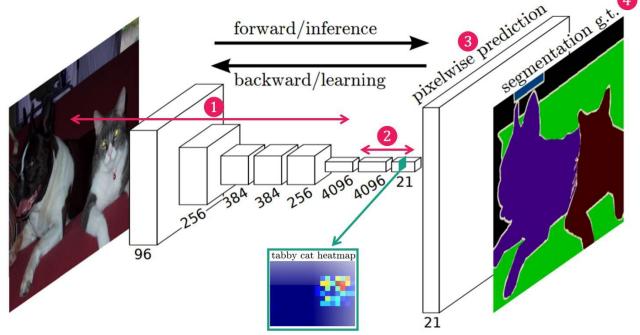




- 1. End-to-end 방식의 Semantic Segmentation 방법을 제안 (pixel-to-pixel)
 - End-to-end: 입력부터 출력까지의 모든 과정을 한번에 수행하는 방법 (①②③④)
 - forward / inference <-> backward/learning 과정을 통해 한번에 학습과 추론 가능

• (2) Fully Convolutional Network (FCN)

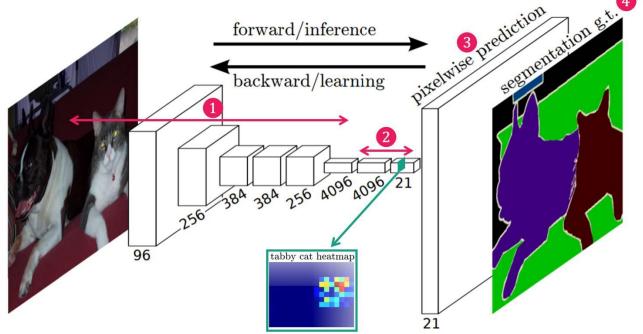




- 2. Pretraining Model for Supervised
 - VGG, GoogleNet 등과 같이 백본으로 사용하는 모델들을 미리 학습된 웨이트를 사용 가능(①②)
 - Pretrained + FineTuning이 가능함

• (2) Fully Convolutional Network (FCN)

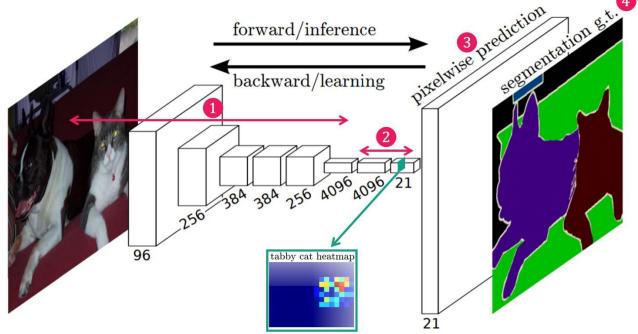
Arbitary Input Size



- 3. 임의의 입력 사이즈에 대해서도 네트워크가 출력을 내보냄 (1x1 Convolution)
 - 어떤 입력 사이즈의 이미지를 넣더라도 동일한 입력 크기를 가지는 출력 결과를 내보냄 (①)
 - 예1) input image size (512, 512) -> output segmentation image size (512, 512)
 - 예2) input image size (256, 256) -> output segmentation image size (256, 256)

• (2) Fully Convolutional Network (FCN)

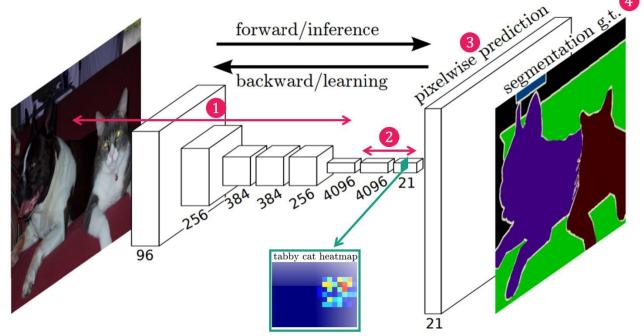
Upsampling for pixelwise preidiction



- 4. Upsampling을 이용해서 Pixel Wise Classfication을 가능하게 함 (②->③)
 - Upsampling (Transposed Convolution)

• (2) Fully Convolutional Network (FCN)

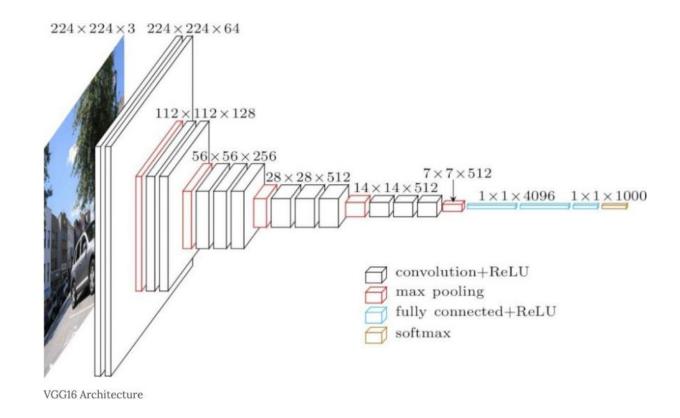
Skip Architecture



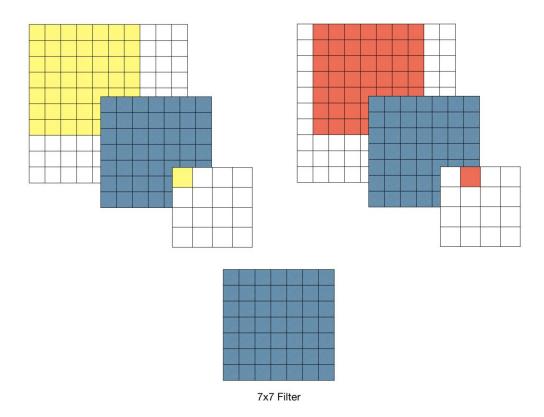
- 5. 낮은 층의 정보와 높은 층의 정보를 skip architecture를 통해서 결합해줌
 - 직선 및 곡선, 색상 등의 낮은 수준의 특징 (local feature) ①
 - 복잡하고 포괄적인 개체 정보가 활성화 (global feature) ②

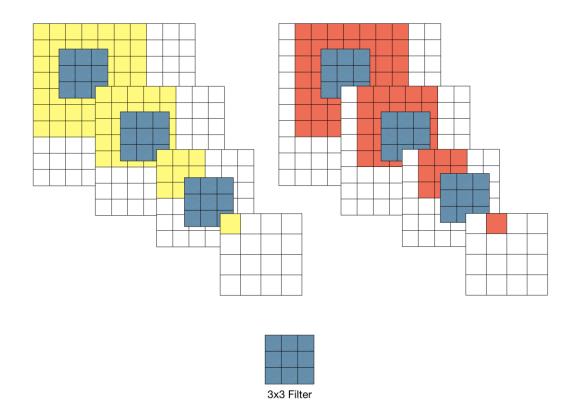
$2.\underset{\text{(1) VGG}}{\text{Related Work}}$

ConvNet Configuration										
A	A-LRN	В	C	D	E					
11 weight	11 weight	13 weight	16 weight	16 weight	19 weight					
layers	layers	layers	layers	layers	layers					
input (224 × 224 RGB image)										
conv3-64	conv3-64	conv3-64	conv3-64	conv3-64	conv3-64					
	LRN	conv3-64	conv3-64	conv3-64	conv3-64					
	maxpool									
conv3-128	conv3-128	conv3-128	conv3-128	conv3-128	conv3-128					
		conv3-128	conv3-128	conv3-128	conv3-128					
	maxpool									
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256					
conv3-256	conv3-256	conv3-256	conv3-256	conv3-256	conv3-256					
			conv1-256	conv3-256	conv3-256					
					conv3-256					
			pool							
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512					
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512					
			conv1-512	conv3-512	conv3-512					
					conv3-512					
			pool							
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512					
conv3-512	conv3-512	conv3-512	conv3-512	conv3-512	conv3-512					
			conv1-512	conv3-512	conv3-512					
					conv3-512					
maxpool										
FC-4096										
FC-4096										
FC-1000										
soft-max										



2. Related Work





2. Related Work

Case Study: VGGNet

[Simonyan and Zisserman, 2014]

Details:

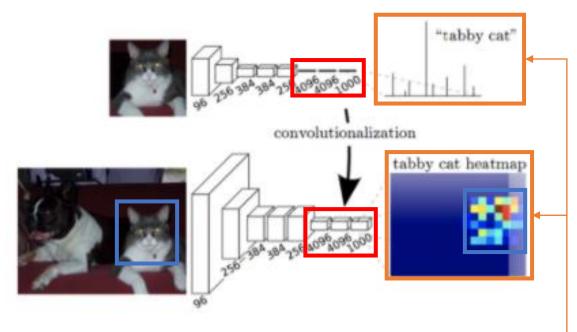
- ILSVRC'14 2nd in classification, 1st in localization
- Similar training procedure as Krizhevsky 2012
- No Local Response Normalisation (LRN)
- Use VGG16 or VGG19 (VGG19 only slightly better, more memory)
- Use ensembles for best results
- FC7 features generalize well to other tasks



출처 : CS231n 17

2 Related Work (2) Fully Convolutional Networks

정의: Fully Connected Layer를 1x1 Convolution으로 변경




Fully Connected vs Fully Convolution

- Fully Connected Layer는 단순하게 개 vs 고양이의 정보만 제공
- Fully Convolutional Layer는 위치 정보를 같이 제공

- 1. 이미지의 위치정보를 기억하기 위함
- 2. 임의의 입력 크기에 대해서도 일관성있는 결과를 생성하려는 의도

(Fully connected layer는 입력의 크기가 동일해야 하는데, Convolution 는 상관없음)

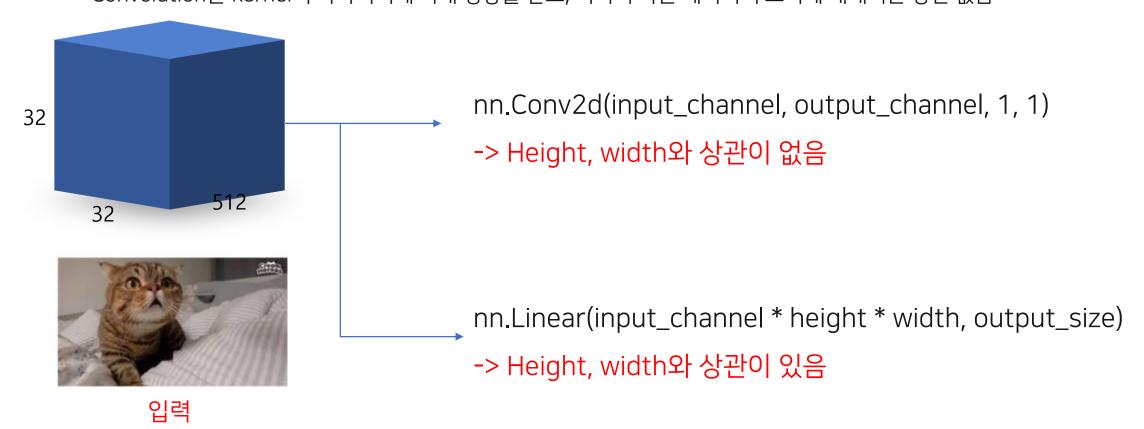
2 Related Work (2) Fully Convolutional Networks



Output 중 Cat에 대한 필터

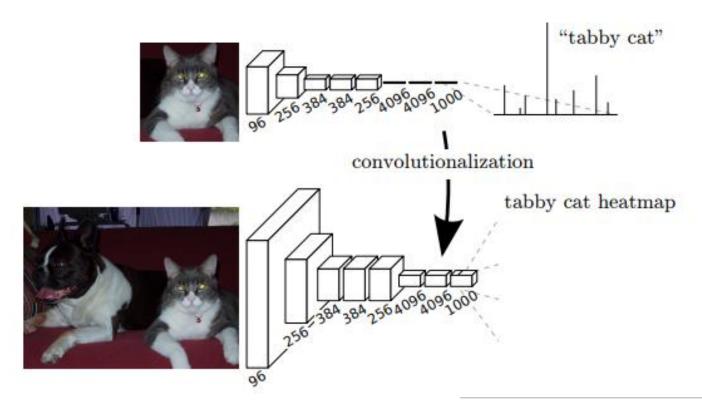
2 Related Work (2) Fully Convolutional Networks

1x1 Convolution을 사용할 경우, 임의의 입력값에 대해서도 상관 없는 이유
-> Convolution은 kernel의 파라미터에 의해 영향을 받고, 이미지 혹은 레이어의 크기에 대해서는 상관 없음



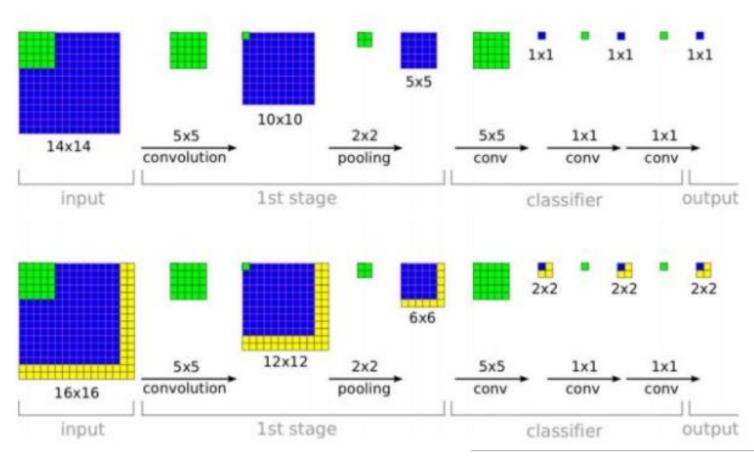
3 Fully convolution networks (1) Adapting classifiers for dense prediction

- Fully Connected Layer to Convolution Layer
 - Fixed sized inputs -> Arbitary Image Size
 - spatial coordinates를 기억
 - Computational Efficiency



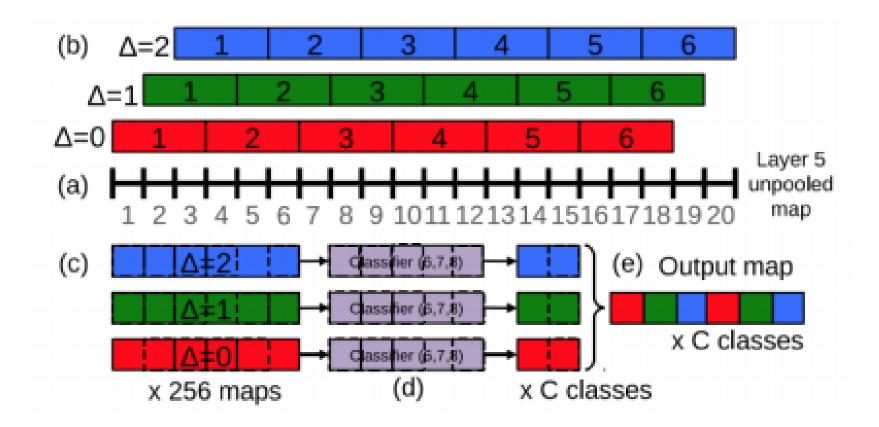
3 Fully convolution networks (2) Shift-and-stitch is filter rarefaction

- - 1. Max-Pooling에 의해서 사라진 정보의 손실을 방지하기 위한 방법



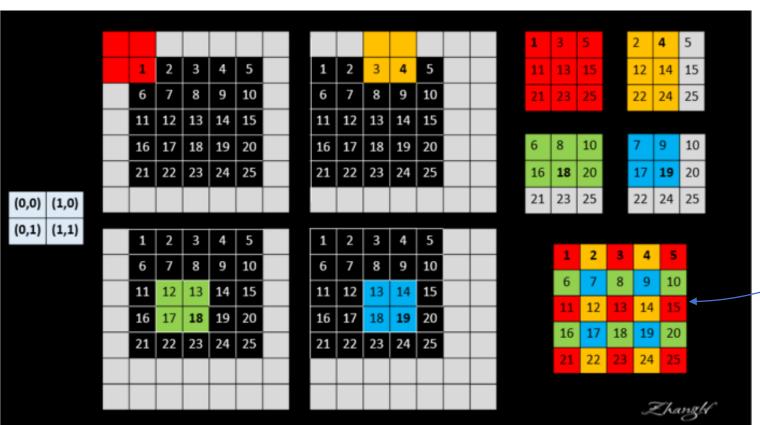
Fully convolution networks • (2) Shift-and-stitch is filter rarefaction

- - Max-Pooling에 의해서 사라진 정보의 손실을 방지하기 위한 방법
 - OverFeat[9] 에서는 Input shifting and output interlacing 을 사용



3 Fully convolution networks (2) Shift-and-stitch is filter rarefaction

- - Max-Pooling에 의해서 사라진 정보의 손실을 방지하기 위한 방법
 - OverFeat[9] 에서는 Input shifting and output interlacing 을 사용

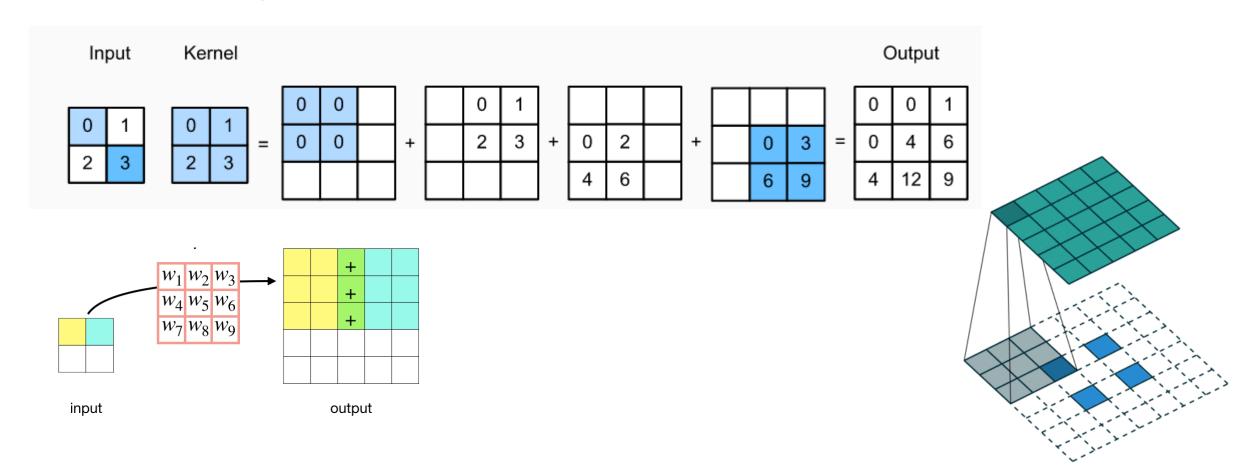


4개의 좌표를 시작으로 하는 2x2 Maxpooling (Stride 2)를 적용하고 결합

3 Fully convolution networks (2) Shift-and-stitch is filter rarefaction

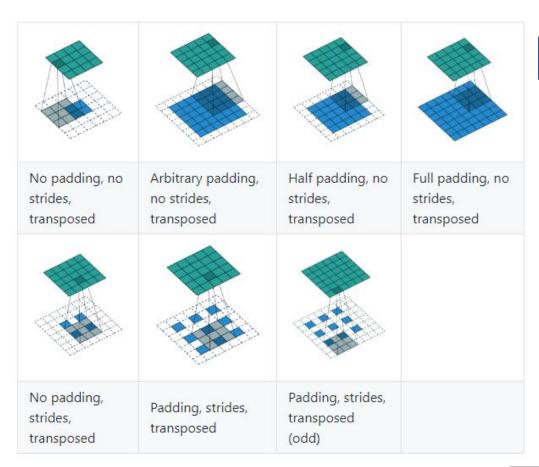
- - Max-Pooling에 의해서 사라진 정보의 손실을 방지하기 위한 방법
 - OverFeat[9] 에서는 Input shifting and output interlacing 을 사용
 - 하지만, 사실 이게 Filters와 strides를 바꾸는 것과 같은 결과를 가짐
 - 이는 이후에 적용은 하지 않고, Skip Architecture를 적용하는게 더 좋았음

☑ Transposed Convolution을 이용해서 coarse -> dense output으로 변경 의미: Max Pooling에 의해서 감소한 이미지의 크기를 원본 이미지의 크기로 복원



☑ Transposed Convolution을 이용해서 coarse -> dense output으로 변경

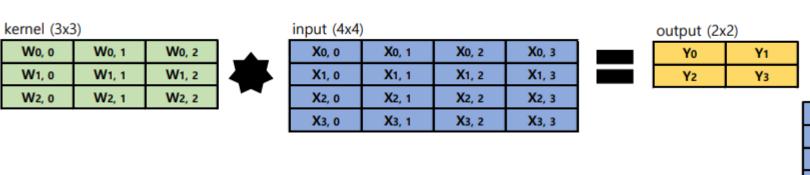
Convolution 된 결과에 Deconvolution을 해도 그대로 나오지 않음. Convolution을 입력값에 대해 미분한 값에 Y를 곱한 값이 출력됨 (의미상으로 Convolution의 Transpose를 계산한 것임)



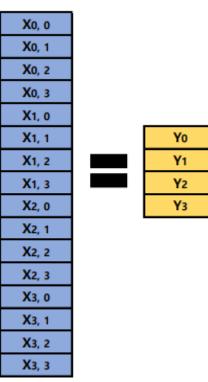
$$TransposedConvolution(Y,W) = Y \cdot rac{\partial Conv(X,W)}{\partial X}$$

크기는 같지만, 연산의 결과는 다를 수 있기에 Deconvolution이라는 표현은 수학적으로는 정확하지 않음

Convolution vs Transposed Convolution



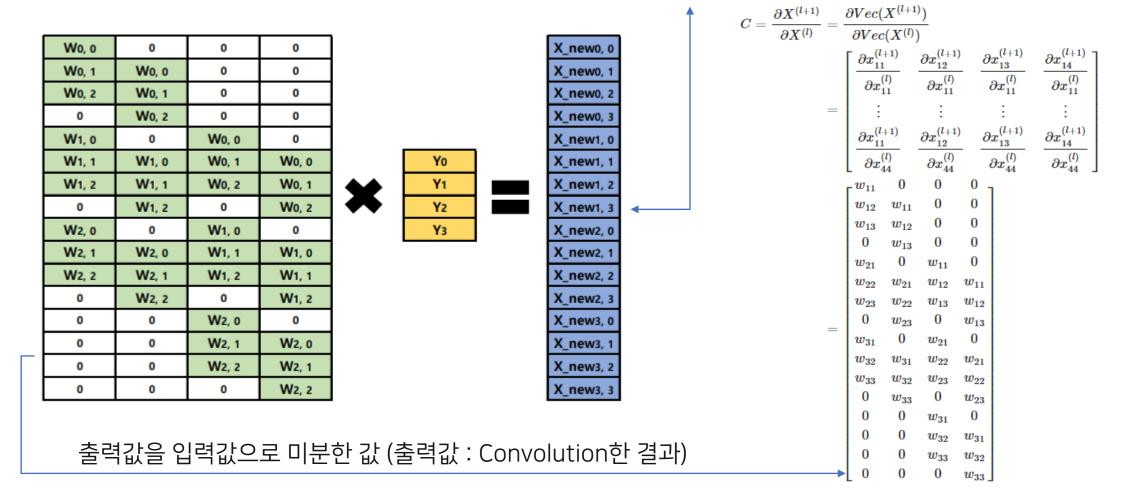
W 0, 0	W0, 1	W 0, 2	0	W1, 0	W 1, 1	W 1, 2	0	W2, 0	W2, 1	W2, 2	0	0	0	0	0
0	W 0, 0	W0, 1	W0, 2	0	W 1, 0	W1, 1	W1, 2	0	W2, 0	W2, 1	W2, 2	0	0	0	0
0	0	0	0	W 0, 0	W0, 1	W0, 2	0	W1, 0	W1, 1	W1, 2	0	W2, 0	W2, 1	W2, 2	0
0	0	0	0	0	W 0, 0	W0, 1	W 0, 2	0	W1, 0	W1, 1	W1, 2	0	W2, 0	W2, 1	W2, 2



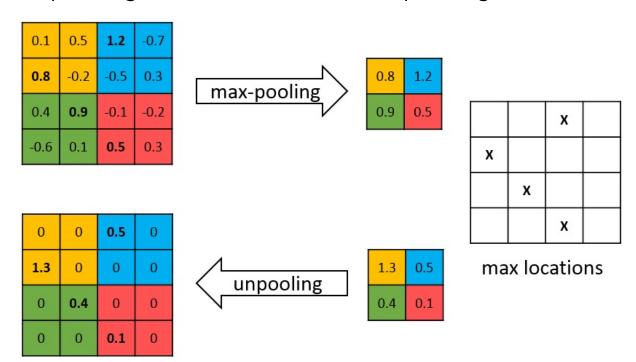


inp	out ((4x4)
-----	-------	-------

X0, 0	X 0, 1	X0, 2	X0, 3
X1, 0	X1, 1	X1, 2	X1, 3
X2, 0	X 2, 1	X2, 2	X2, 3
X3, 0	X 3, 1	X3, 2	Хз, з

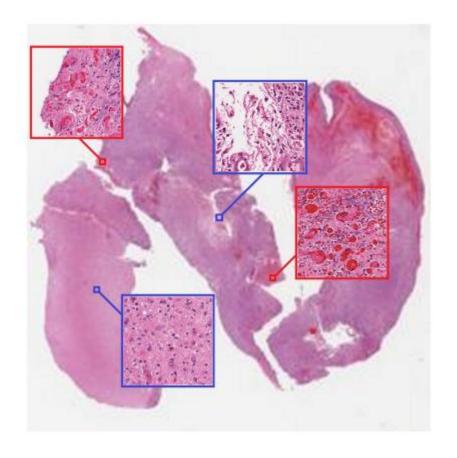


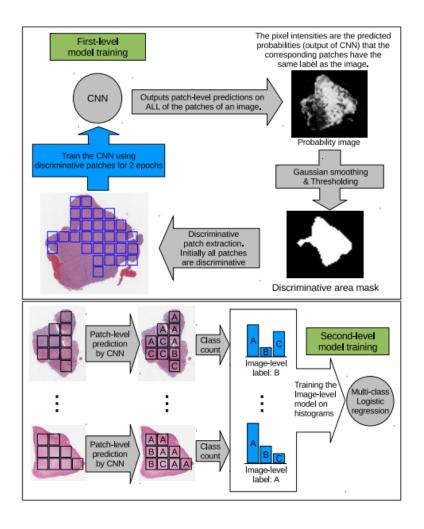
- ✓ 그 외의 coarse -> dense output으로 변경하는 방법
 - Pooling을 사용하지 않거나, Pooling의 Stride를 줄임으로서 애초에 Feature map을 늘리는 경우
 - 파라미터가 너무 많아지는 문제가 있음
 - Receptive Field가 작아짐
 - Unpooling을 이용한 방법 (Max Unpooling, Bilinear interpolation)



3 Fully convolution networks (4) Patchwise training is loss sampling

What is the Patch-wise Training?





3 Fully convolution networks (4) Patchwise training is loss sampling

Patchwise training vs fully convolutional training

[patchwise training] [fully convolutional training]

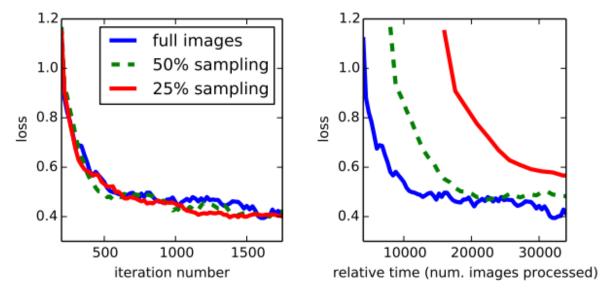




- patchwise training을 사용시에 효과적인 학습이 가능
 - 배경과 같이 사진의 대부분을 차지하는 영역(redundancy)을 학습에서 제외할 수 있음
 - 샘플링을 통해 클래스간의 균형을 맞출 수 있음
 - Fully convolutional의 경우 pixel이 sptial correlation을 가지는데 이를 해결할 수 있음
 - 학습데이터와 검증데이터간의 분포를 비슷하게 맞출 수 있음
 - 이를 통해 수렴하는 속도도 빨라지는 장점이 있음

3 Fully convolution networks (4) Patchwise training is loss sampling





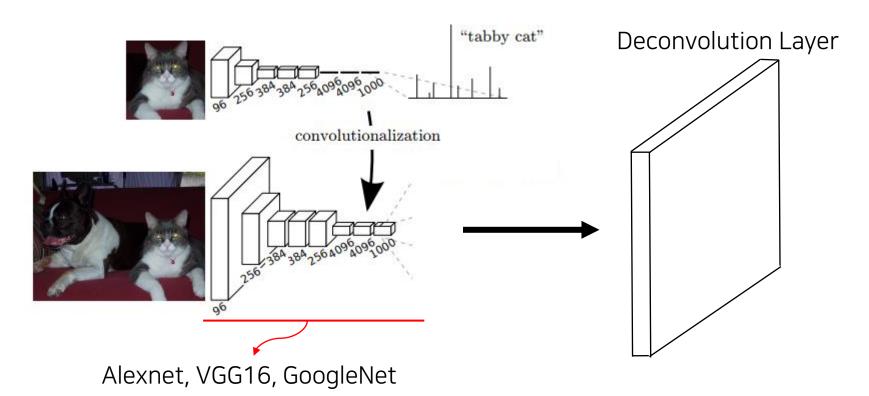
- 2. 실제 실험결과 Patchwise training의 효과는 거의 없었음
 - patch-wise 와 fully convolutional 방법은 iteration에 대한 loss는 비슷했음
 - 하지만 relative time에서 fully convolutional이 효과가 좋았음
 - class imbalance 같은 경우는 weight를 주거나 loss를 sampling 해서 해결할 수도 있음

Segmentation Architecture (0) Overview

- Fully Connected Layer
 - 1. ILSVRC 분류기 (Alexnet, VGG16, GoogleNet)에 FCN을 결합해서 Semantic Segmentation을 수행
 - VGG19의 경우 16과 큰 차이가 없었음
 - GoogleNet의 경우 average pooling layer를 버리고 final loss layer만 사용
 - 2. Pretrained된 모델을 가져와서 FineTuning을 수행
 - Skip architecture를 도입해서 깊은 정보와 얕은 정보를 결합함
 - 이를, PASCAL VOC 2011 segmentation challenge에 실험
 - Loss: pixel multinomial logistic loss / Metric: mean pixel intersection over union (Mean IU)
 - 참고로 모호한 mask들은 무시하고 진행했음

4 Segmentation Architecture (1) From classifier to dense FCN

- (1) I TOTTI Classifier to defise i civ
- How to apply ILSVRC Classifier to FCN?
 - 1. ILSVRC 분류기 (Alexnet, VGG16, GoogleNet)에 FCN을 결합해서 Semantic Segmentation을 수행
 - Final Classifier Layer를 버리고 Fully Connected Layer를 1x1 Convolution으로 대체
 - Upsampling을 위한 Deconvolution layer를 추가 (Bilinearly upsampling)



4 Segmentation Architecture (1) From classifier to dense FCN

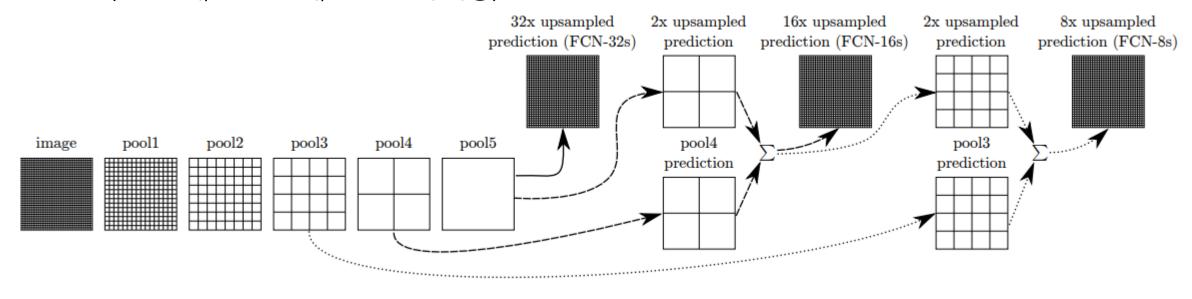


2. Fine Tuning

- Classification -> Segmentation

-	FČN- AlexNet	FCN- VGG16	FCN- GoogLeNet ⁴
mean IU	39.8	56.0	42.5
forward time	50 ms	210 ms	59 ms
conv. layers	8	16	22
parameters	57M	134M	6M
rf size	355	404	907
max stride	32	32	32

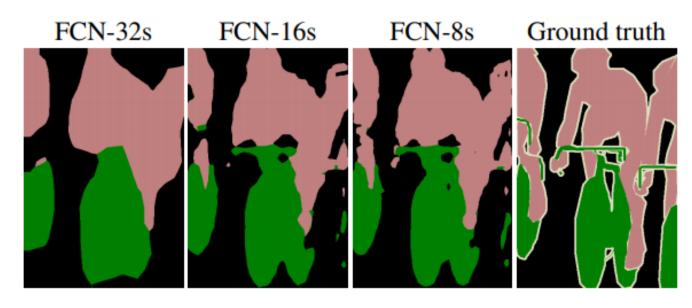
- (2) Combining what and where
- How to apply ILSVRC Classifier to FCN?
 - 3. Segmentation의 성능을 향상시키기 위한 Skip Architecture 사용
 - pooling의 결과와 upsampled의 결과를 결합시킴
 - 얼마나 얕은 정보까지 사용했냐에 따라서 FCN-8s부터 FCN-32s까지 존재 (8은 2개, 16은 1개, 32는 0개 사용)



<u>A</u> Segmentation Architecture

• (2) Combining what and where

- How to apply ILSVRC Classifier to FCN?
 - 3. Segmentation의 성능을 향상시키기 위한 Skip Architecture 사용
 - pooling의 결과와 upsampled의 결과를 결합시킴
 - 얼마나 얕은 정보까지 사용했냐에 따라서 FCN-8s부터 FCN-32s까지 존재
 - 최대한 얕은 정보까지 결합할 수록 성능이 계속 좋아짐

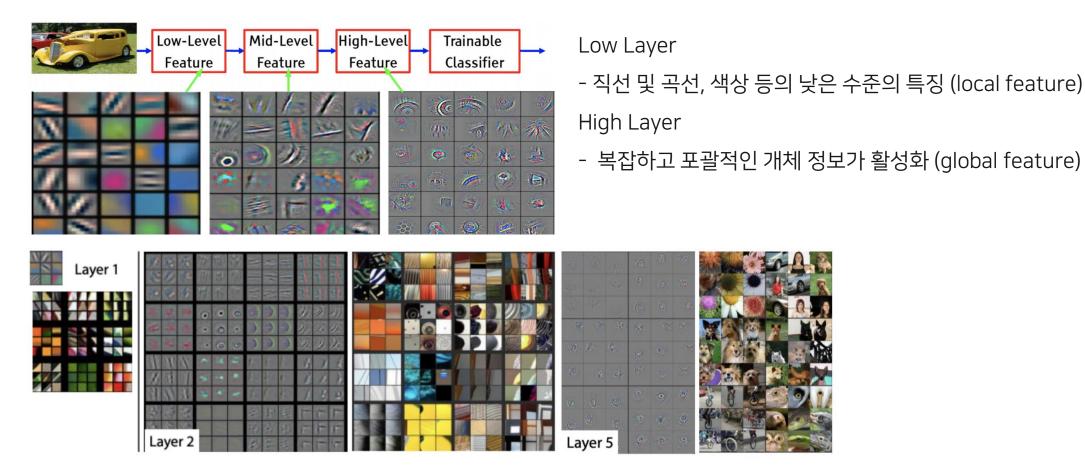


	_	mean		
	acc.	acc.	IU	IU
FCN-32s-fixed	83.0	59.7	45.4	72.0
FCN-32s	89.1	73.3	59.4	81.4
FCN-16s	90.0	75.7	62.4	83.0
FCN-8s	90.3	75.9	62.7	83.2

• (2) Combining what and where

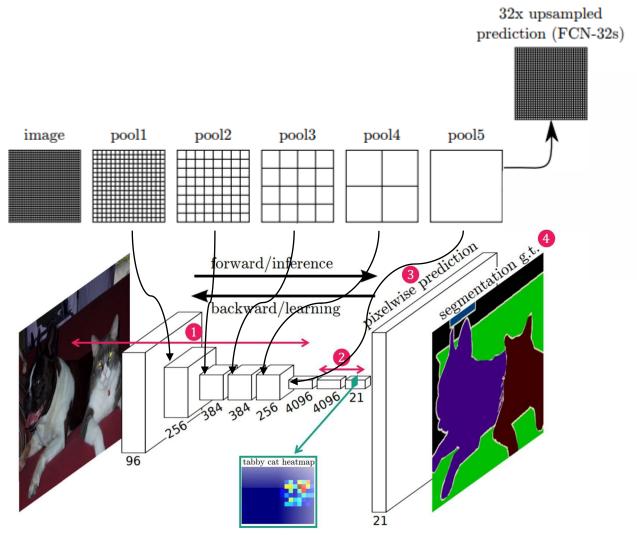
How to apply ILSVRC Classifier to FCN?

얕은 층의 정보는 Local Feature를 깊은 층은 Global Feature를 가지고 있어서 결합하는게 의미가 있음

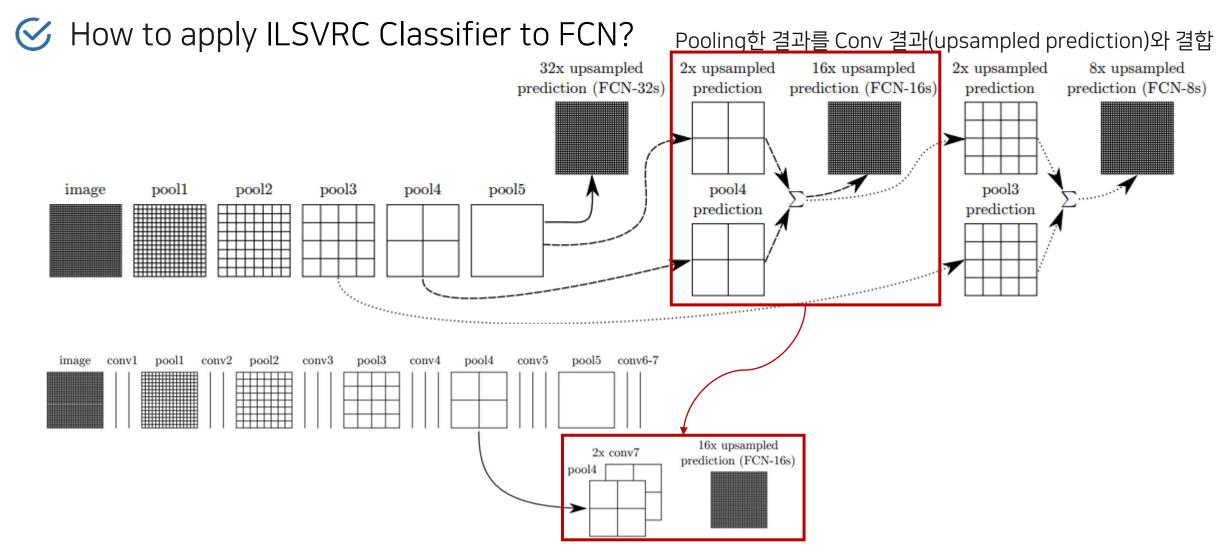


4 Segmentation Architecture (2) Combining what and where





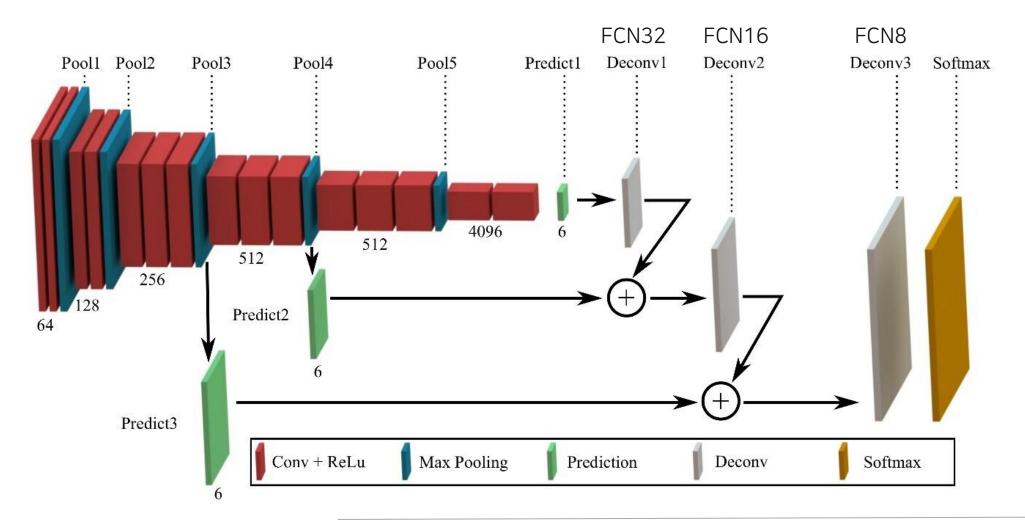
4 Segmentation Architecture (2) Combining what and where



• (2) Combining what and where

How to apply ILSVRC Classifier to FCN?

Pooling한 결과를 Conv 결과(upsampled prediction)와 결합



1 Segmentation Architecture (2) Combining what and where



How to apply ILSVRC Classifier to FCN?

FCN32

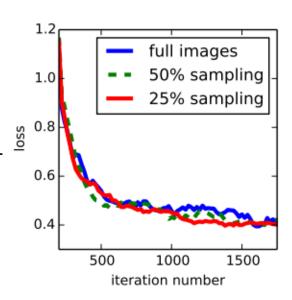
```
self.conv1_1 = nn.Conv2d(3, 64, 3, padding=100)
self.relu1_1 = nn.ReLU(inplace=True)
self.conv1_2 = nn.Conv2d(64, 64, 3, padding=1)
self.relu1 2 = nn.ReLU(inplace=True)
self.pool1 = nn.MaxPool2d(2, stride=2, ceil_mode=True) # 1/2
self.conv2_1 = nn.Conv2d(64, 128, 3, padding=1)
self.relu2_1 = nn.ReLU(inplace=True)
self.conv2_2 = nn.Conv2d(128, 128, 3, padding=1)
self.relu2 2 = nn.ReLU(inplace=True)
self.pool2 = nn.MaxPool2d(2, stride=2, ceil_mode=True) # 1/4
# conv3
self.conv3_1 = nn.Conv2d(128, 256, 3, padding=1)
self.relu3_1 = nn.ReLU(inplace=True)
self.conv3_2 = nn.Conv2d(256, 256, 3, padding=1)
self.relu3_2 = nn.ReLU(inplace=True)
self.conv3 3 = nn.Conv2d(256, 256, 3, padding=1)
self.relu3_3 = nn.ReLU(inplace=True)
self.pool3 = nn.MaxPool2d(2, stride=2, ceil_mode=True) # 1/8
self.conv4_1 = nn.Conv2d(256, 512, 3, padding=1)
self.relu4_1 = nn.ReLU(inplace=True)
self.conv4_2 = nn.Conv2d(512, 512, 3, padding=1)
self.relu4_2 = nn.ReLU(inplace=True)
self.conv4_3 = nn.Conv2d(512, 512, 3, padding=1)
self.relu4 3 = nn.ReLU(inplace=True)
self.pool4 = nn.MaxPool2d(2, stride=2, ceil_mode=True) # 1/16
```

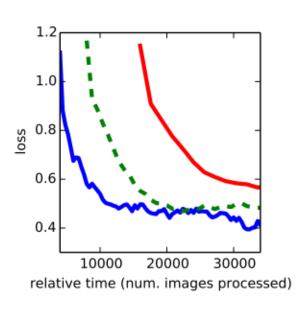
```
self.conv5_1 = nn.Conv2d(512, 512, 3, padding=1)
self.relu5_1 = nn.ReLU(inplace=True)
self.conv5_2 = nn.Conv2d(512, 512, 3, padding=1)
self.relu5 2 = nn.ReLU(inplace=True)
self.conv5_3 = nn.Conv2d(512, 512, 3, padding=1)
self.relu5_3 = nn.ReLU(inplace=True)
self.pool5 = nn.MaxPool2d(2, stride=2, ceil mode=True) # 1/32
# fc6
self.fc6 = nn.Conv2d(512, 4096, 7)
self.relu6 = nn.ReLU(inplace=True)
self.drop6 = nn.Dropout2d()
# fc7
self.fc7 = nn.Conv2d(4096, 4096, 1)
self.relu7 = nn.ReLU(inplace=True)
self.drop7 = nn.Dropout2d()
self.score_fr = nn.Conv2d(4096, n_class, 1)
self.upscore = nn.ConvTranspose2d(n_class, n_class, 64, stride=32,
                                  bias=False)
```

FCN16

```
self.score fr = nn.Conv2d(4096, n class, 1)
self.score_pool4 = nn.Conv2d(512, n_class, 1)
self.upscore2 = nn.ConvTranspose2d(
    n class, n class, 4, stride=2, bias=False)
self.upscore16 = nn.ConvTranspose2d(
    n_class, n_class, 32, stride=16, bias=False)
h = self.score_fr(h)
h = self.upscore2(h)
upscore2 = h # 1/16
h = self.score pool4(pool4)
h = h[:, :, 5:5 + upscore2.size()[2], 5:5 + upscore2.size()[3]]
score pool4c = h # 1/16
h = upscore2 + score pool4d
h = self.upscore16(h)
```

- (3) Experiemnt Framework
- Optimization, Fine-tuning, Patch Sampling
 - Optimizer
 - SGD with momentum (minibatch size of 20 images)
 - $lr: 10^{-3}, 10^{-4}, 5^{-5}$ for FCN-AlexNet, FCN-VGG16, FCN-GoogLeNet
 - momentum: 0.9
 - weight decay : 5^{-4} , 2^{-4}
 - zero-initialize > random initialize
 - Drop Out
 - Fine-tuning
 - Last Layer vs full fine-tuning
 - Patch Sampling
 - 전체 이미지를 사용하는게 가장 성능이 좋았음





Segmentation Architecture (3) Experiemnt Framework

- Class Balancing, Dense Prediction, Augmentation
 - 4. Class Balancing
 - weighting / sampling -> 사용 x
 - Dense Prediction
 - Shift and stitch / filter rarefaction equivalent or not -> 사용 x
 - Augmentation
 - "jittering"(잡음/채도) -> 사용효과미비

5. Results (1) Metrics

❷ Pixel Accuracy클래스별 전체 픽셀에서 예측에 성공한 픽셀의 수

pixel accuracy: $\sum_i n_{ii} / \sum_i t_i$

5. Results 1. Metrics

Mean Accuracy

클래스별 전체 픽셀에서 예측에 성공한 픽셀의 수

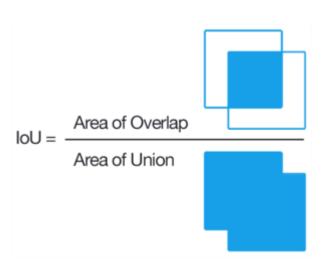
mean accuraccy: $(1/n_{\rm cl}) \sum_i n_{ii}/t_i$

5. Results 1. Metrics



클래스별 전체 픽셀에서 예측에 성공한 픽셀의 수

mean IU:
$$(1/n_{cl}) \sum_{i} n_{ii} / (t_i + \sum_{j} n_{ji} - n_{ii})$$



5. Results 1. Metrics

Frequency weighted IU 클래스별 전체 픽셀에서 예측에 성공한 픽셀의 수

frequency weighted IU:


$$\left(\sum_{k} t_{k}\right)^{-1} \sum_{i} t_{i} n_{ii} / \left(t_{i} + \sum_{j} n_{ji} - n_{ii}\right)$$

6. Concolusion (1) Advantages

- 1. End-to-end 방식의 Semantic Segmentation 방법을 제안
 - 기존의 모델은 전처리 및 후처리가 있거나 복잡한 형태를 가지지만, FCN은 되게 간단한 구조를 가짐
 - 빠른 학습속도와 추론속도를 가지고 있음
- 2. Pretrained된 모델을 사용할 수가 있음
 - BackBone으로 Pretrained된 모델을 사용하고 마지막의 Fully Connected Layer만 1x1 Convolutional Layer으로 변경해주면 되는 구조
 - Pretrained + Fine Tuning이 가능함
- 3. Skip Architecture 구조를 이용해서 다양한 resolution의 결과를 합침
- 4. 다양한 실험과정을 통해서 최적의 결과를 도출했고, 다양한 데이터에 대해 실험을 진행해서 성능 평가

6. Concolusion (2) Disadvantages

- 1. End-to-End 방식이 가지고 있는 문제점들을 보유하고 있음
 - 입력 데이터가 부족한 경우 학습이 잘 되지 않음
- 2. 세부적인 외곽선들을 잘 못잡는 문제가 있음
- 3. 작은, 큰 물체들을 잘 잡지 못하는 문제가 있음
- 4. 큰 물체의 경우 내부에 Object들이 섞이는 문제가 있음
- 5. 논문 자체의 그림같은 부분에서 불친절할 부분이 많음

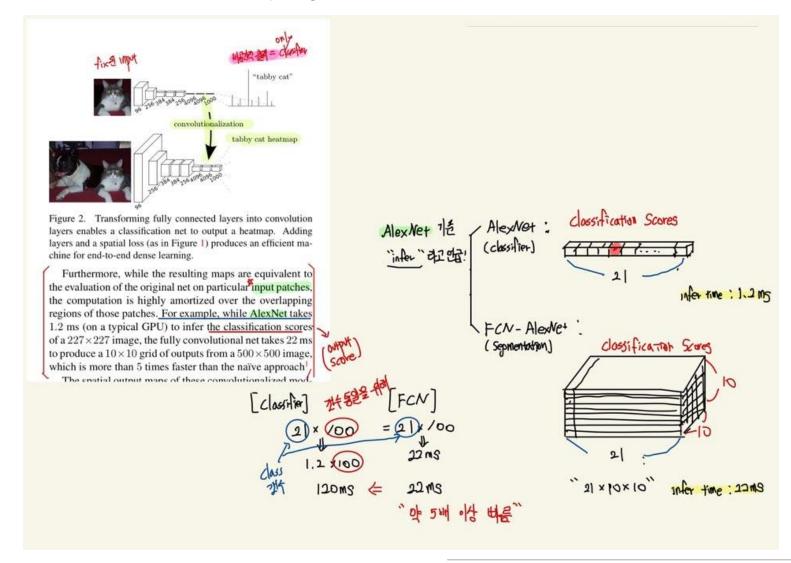


7 Appendix

- 1. J. Long, E. Shelhamer, and T. Darrell. Fully convolutional networks for semantic segmentation. In CVPR, 2015
- 2. A. Krizhevsky, I. Sutskever, and G. E. Hinton. Imagenet classification with deep convolutional neural networks. In NIPS, 2012
- K. Simonyan and A. Zisserman. Very deep convolutional networks for large-scale image recognition. CoRR, abs/1409.1556, 2014
- 4. C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, and A. Rabinovich. Going deeper with convolutions. CoRR, abs/1409.4842, 2014
- 5. R. Girshick, J. Donahue, T. Darrell, and J. Malik. Rich feature hierarchies for accurate object detection and semantic segmentation. In Computer Vision and Pattern Recognition, 2014
- 6. J. Long, N. Zhang, and T. Darrell. Do convnets learn correspondence? In NIPS, 2014
- 7. C. Farabet, C. Couprie, L. Najman, and Y. LeCun. Learning hierarchical features for scene labeling. Pattern Analysis and Machine Intelligence, IEEE Transactions on, 2013
- 8. S. Gupta, R. Girshick, P. Arbelaez, and J. Malik. Learning rich features from RGB-D images for object detection and segmentation. In ECCV. Springer, 2014
- 9. P. Sermanet, D. Eigen, X. Zhang, M. Mathieu, R. Fergus, and Y. LeCun. Overfeat: Integrated recognition, localization and detection using convolutional networks. In ICLR, 2014
- 10. Investigations on the inference optimization techniques and their impact on multiple hardware platforms for Semantic Segmentation

7 Appendix

- (2) 이해하지 못했던 부분 (헷갈린 부분)
 - 1. 500 x 500 -> 10 x 10 output grid 생성



감사합니다